

QKV 射影を 1 枚に共有した Transformer の精度は取り戻せるか

岳 子然¹ 架田 琉稀² ルパージュ イヴ¹

¹ 早稲田大学 大学院情報生産システム研究科 ² 旭川工業高等専門学校
ron@suou.waseda.jp, p268009@edu.asahikawa-nct.ac.jp,
yves.lepage@waseda.jp

概要

Transformer のアテンションは、クエリ Q ・キー K ・バリュー V を作るために 3 枚の射影行列 W_Q, W_K, W_V を持つ。これを 1 枚の W_S にまとめると (単純共有), モデル全体のパラメータ数を 15–36% 減らせるが, Q, K, V が互いに似てしまい, 翻訳の BLEU が落ちる。本研究は, この落ちた BLEU を, 削減率をほとんど損なわずに取り戻す手段として類推関係を用いる。類推関係 $a : b :: c : d$ (a の b に対する関係が c の d に対する関係に等しい) を保つ操作は, 4 項の並べ替え 24 通りのうちの 8 通りと, 4 項に共通の非負の倍率だけである。 W_S の出力を 4 チャンネルずつの組に切って類推の 4 項とみなし, この学習パラメータを持たない操作を役割ごとに異なる重みで掛けることで, 1 枚の W_S から互いに異なる Q, K, V を作り分ける。並べ替える範囲は, 組の中に限る局所置換と, Beneš network で d チャンネル全体へ広げる大域置換の 2 通りを試した。3 つのデータセットで検証したところ, 局所置換は翻訳において, 単純共有が失った BLEU の約 3 分の 1 を有意に取り戻したが, 大域置換はそれを上回らず, COGS では最低だった。どちらも削減率は単純共有とほぼ同じである。

1 はじめに

我々の最終的な目標は, 類推という一つの数学的な道具で, 大規模言語モデルの学習時間・パラメータ数・学習データ量を減らすことである。本稿はこのうちパラメータ数を扱う第一段階である。

アテンション 1 箇所は W_Q, W_K, W_V, W_O の 4 枚の $d \times d$ 行列を持つ [1]。 W_Q, W_K, W_V を 1 枚の W_S にまとめると (以下, 単純共有), 1 箇所あたり $2d^2 - d$ 個が消え, モデル全体の 15–36%にあたる (表 1)。しかし Q, K, V が同じ $S = XW_S$ から作られるため互いに似てしまい, 精度が落ちる。Kayyam ら [2] は,

完全共有 $Q=K=V$ で言語モデルの検証 perplexity が 5.11 から 6.41 (+25.4%) へ悪化することを示した。

落ちた精度を, パラメータ数をほとんど変えずに取り戻したい。そこで類推関係 $a : b :: c : d$ を保つ操作を借りる。4 項の並べ方 24 通りのうち類推を保つのは 8 通りだけで [3], 学習パラメータを持たない 4×4 の置換行列で書ける (図 2)。4 項すべてに同じ非負の倍率を掛けても類推は保たれる。共有射影の出力を 4 チャンネルずつの組に切り, 役割ごとに 8 置換の混合と倍率を掛けるのが局所置換である。組の外へは動けないという制約を外すため, Beneš network [4] で d チャンネル全体の並べ替えを先に掛けるのが大域置換である。どちらも単純共有から出発する提案法の 2 通りの形であり, 本稿では両者を並べて比べる (図 1)。

独自性は 3 点ある。第一に, 類推を保つ操作の集合を, Q, K, V の役割を作り分ける変換の設計原理として用いた研究は我々の知る限りない (ヘッド間の共有 [5] や系列位置の置換 [6, 7] とは対象が異なる)。第二に, 対角行列では原理的に破れないスコアの対称性を, 削減率をほとんど損なわないまま破る。第三に, 利得の出どころを, 類推由来ではない対照の置換集合との比較で検証する。検証する問いは, (1) 同じパラメータ数で単純共有を改善するか, (2) 同規模の通常 Transformer を上回るか, (3) 類推由来の 8 置換は他の 8 置換より有効か, (4) d チャンネル全体の大域置換は 4 チャンネルの組の中の局所置換を上回るか, の 4 つである。

2 提案法

2.1 前提：単純共有と 2 つの弱点

出発点は, 1 枚の射影行列 W_S と, 役割ごとに異なる対角行列 D_Q, D_K, D_V を用いる共有重みアテンション [8], すなわち第 1 節の単純共有である (図 1(b)) : $S = XW_S + b_S$, $(Q, K, V) = (SD_Q, SD_K, SD_V)$ 。




図 1 アテンション 1 箇所の射影の変化. (b) 単純共有は役割別の対角行列 D_r (対角成分だけを縦に並べて描いた) しか持たないので QK^T が必ず対称になる. (c) 局所置換は z を 4 チャンネルずつの組に切り、役割 r ごとのルータが 8 置換を混ぜた M_r (格子の濃さが重み) と倍率 λ_r を掛ける. (d) 大域置換は K, V に Π_K, Π_V を先に掛け、倍率は使わない. (c) と (d) は (b) から出発した並列の 2 案である.




図 2 類推関係 $a:b::c:d$ を保つ 8 通りの並べ替えを表す 4×4 置換行列 $P_1, \dots, P_8$ (位数 8 の二面体群 D_8). 列は入力位置 a, b, c, d , 行は出力位置 1-4, 塗りが 1. 24 通りのうち外項 $\{a, d\}$ と内項 $\{b, c\}$ への分割を保つのはこの 8 通りだけである.




図 3 共有射影の出力 z から役割別の z_r を作る線形部分 (ゲート g_r と対角 d_r は省略, $\times$ は行列の積). 下の矢印が掛かる順で、右端の入力 z にまず①、次に②が掛かって左端の出力 z_r になる. 大域置換では①で Π_r ($r \in \{K, V\}$) により並べ替えるので、離れたチャンネルも同じ組に入れられる.




図 4 Beneš network で表す大域置換 Π_K, Π_V ($d=8$ の例). 濃い縦棒 1 本が 2×2 スイッチ 1 個で、つないだ 2 チャンネルを入れ替えるかどうかを 1 ビットで選ぶ. $(2 \log_2 d - 1)$ 段・各段 $d/2$ 個で $d!$ 通りすべての置換を表せる ($d=512$ なら 4,352 個=密な $d \times d$ 行列の 1.66%).

弱点は 2 つある. チャンネル間で混ぜられない: 対角行列は各チャンネルを個別に定数倍するだけで、異なるチャンネルの情報を組み合わせられない. 対称: $D_Q D_K$ は対角なのでスコア $QK^T = S D_Q D_K S^T$ は必ず対称になり、単語 i が j を見る強さと j が i を見る強さが常に等しいので、言語の「向き」を表せない.

2.2 類推関係を保つ 8 つの並べ替え

類推 $a:b::c:d$ は、対称 $c:d::a:b$, 内項交換 $a:c::b:d$, 比の逆転 $b:a::d:c$ のいずれによっても同じ類推を表す. これらが生成する入れ替えは 18 世紀の百科全書 [9] 以来の 8 通りで、位数 8 の二面体群 D_8 をなす [3] (図 2). 4 項に同じ非負の倍率

$\lambda \geq 0$ を掛けても類推は保たれる. 本稿が借りるのはこの 2 操作だけであり、以下では 2 操作の下で保たれる $a:b::c:d$ を類推関係と呼ぶ.

2.3 局所置換: 組の中の混合

$z = xW_S + b_S$ を 4 チャンネルずつの組に切り、各組を類推の 4 項とみなす. 役割 $r \in \{Q, K, V\}$ ごとに、文脈ベクトル u から 8 つの置換の混合重みを計算する小さな線形層 (以下、ルータと呼ぶ) を置く:

$$p_r(u) = \text{softmax}(R_r u + b_r), \quad M_r(u) = \sum_{c=1}^8 p_{r,c}(u) P_c. \quad (1)$$

$M_r(u)$ は各行と各列の和がともに 1 になる行列 (二重確率行列) であり、組の値を平均に近づけることしかできない. そこで大きさを戻す非負の倍率 $\lambda_r(u)$ と、変換後の値と元の z をどの割合で混ぜるかを定めるゲート $g_r \in [0, 1]$ を置き、役割変換を

$$T_r(z; u) = d_r \odot [z + g_r \{\lambda_r(u) M_r(u) z - z\}] \quad (2)$$

とする. d_r は単純共有から引き継ぐ対角である. $g_r \rightarrow 0$ で単純共有に帰着するので、提案モデルは単純共有を特殊な場合として含む. 組の作り方とルータの入力 u を変えた 5 つの変種を表 2 に示す. この

表 1 モデル構成, 標準モデルの部品別パラメータ数 (括弧内は%), 射影共有で消える数 ΔP (式 (3)) と削減率 (式 (4)). 構成がデータセットごとに違うのは, そのデータセットで公表されている数値が報告されたときの構成をそのまま用いたためである.

データセット	モデル構成							標準モデルの部品別パラメータ数					射影共有	
	d	f	L_e	L_d	ヘッド	V	L_e+2L_d	埋め込み Vd	アテンション	FFN	LayerNorm	合計	ΔP	削減率
COGS	512	512	2	2	8	835	6	0.43M (4.8)	6.30M (71.3)	2.10M (23.8)	0.01M (0.1)	8.84M	3.14M	35.53%
IWSLT14	512	1,024	6	6	4	10,000	18	5.12M (14.0)	18.91M (51.6)	12.60M (34.4)	0.03M (0.1)	36.67M	9.43M	25.71%
Multi30k	128	256	4	4	4	10,000	12	1.28M (49.1)	0.79M (30.4)	0.53M (20.2)	0.01M (0.2)	2.61M	0.39M	15.03%

うちトークン別 (1 トークン内の連続する 4 チャンネルを 1 組とし, そのトークンのベクトル全体を u とする) だけは系列位置ごとに独立に計算できるのでデコーダにも置き, 全アテンションに置いたものを全箇所と呼ぶ.

2.4 大域置換 (Beneš)

式 (2) の $M_r(u)$ は 4×4 なので, 全体としては 4×4 のブロックが対角に並んだ $d \times d$ 行列を掛けており, たとえば 1 番目のチャンネルの値は 1-4 番目のチャンネルの位置にしか移れない (図 3 左). $d \times d$ の置換行列を直接学習させようにも候補は $d!$ 通り ($d = 128$ でも 10^{215} 超) あって softmax では選べない.

そこで Beneš network [4] を用いる. 2 本の線を「入れ替える／入れ替えない」だけの 2×2 スイッチを段状に並べた回路で, $\frac{d}{2}(2\log_2 d - 1)$ 個のスイッチだけで $d!$ 通りすべての置換を表せる (図 4). 実装では各スイッチを 1 個の実数で持ち, 順伝播ではその符号で入れ替えの有無を決めて厳密な置換を適用し, 逆伝播では sigmoid 関数で近似した勾配を流す. Q には置換を掛けず, K と V にそれぞれ独立な静的置換 Π_K, Π_V を掛けてから, 第 2.3 節と同じ組の中の混合を行う: $K = T_K(\Pi_K z; u)$, $V = T_V(\Pi_V z; u)$ (図 3 右). Q に置換を掛けないのは, Q だけならば W_S を $W_S \Pi_Q^T$ と置き直せば同じことになり, 新しい自由度にならないからである. 3 つの役割が W_S を共有しているので, Q を並び順の基準に固定したうえでの Π_K, Π_V だけが実際の自由度になる. なおこの変種は倍率を持たない ($\lambda_r \equiv 1$).

なぜ対称性が破れるか $Q = SA_Q$, $K = SA_K$ と書くと $QK^T = SA_Q A_K^T S^T$ であり, 中央の $A_Q A_K^T$ が対称でなければスコアは対称でない. 対角行列の積は必ず対称だが, 置換行列の積はそうではない (たとえば $P_2 P_5^T = P_6$ は対称でない). 提案法は役割ごとに異なるルータと大域置換を持つので非対称なスコアを表現でき, 第 2.1 節の 2 つの弱点を同時に解消できる, というのが本稿の仮説である.

3 モデルの大きさ と 削減率

記号は, d がモデル次元, f が FFN 中間層の次元, L_e がエンコーダ層数, L_d がデコーダ層数, V が語彙サイズである. アテンションはエンコーダの自己アテンションが L_e 箇所, デコーダの自己アテンションと交差アテンションが L_d 箇所ずつあるので合計 $L_e + 2L_d$ 箇所, FFN は各層に 1 個ずつなので $L_e + L_d$ 個である. バイアスと LayerNorm も含めて数えると, モデル全体は式 (4) の分母の 4 項の和になる. 3 枚を 1 枚にすると 1 箇所あたり $3(d^2 + d)$ が $(d^2 + d)$ になり, かわりに対角 3 本 $3d$ が増えるので, 消えるのは

$$\Delta P = (L_e + 2L_d)\{2(d^2 + d) - 3d\} = (L_e + 2L_d)(2d^2 - d) \quad (3)$$

である. 本稿で削減率と呼ぶその割合を約めずに書けば式 (4) になる (表 1). バイアスと LayerNorm を無視すれば, 削減率はアテンションが全体に占める割合のちょうど半分である (表 1 の IWSLT14 でも 51.6% に対し 25.71%).

表 1 の構成がデータセットごとに違うのは, 同じ Transformer であっても, データセットごとに, そのデータセットで公表されている数値が報告されたときの構成 (d , f , 層数, ヘッド数) をそのまま用いたためである. 学習設定も同じ出典 [10, 11, 12] に合わせ, 全モデルで共通にした.

提案法が使うパラメータは 1 箇所あたり局所置換が最大 $3(9d + 10)$ 個, 大域置換が $3(8d + 9) + d(2\log_2 d - 1)$ 個で, 全アテンション箇所の分を合計しても単純共有の 2% 以内なので, 削減率はほとんど変わらない (表 2).

4 実験設定

通常の Transformer (標準), 単純共有とパラメータ数がほぼ揃うようにモデル次元 d と FFN 次元 f を狭めた通常の Transformer (同規模標準), 単純共有, 局所置換の 5 変種, 大域置換 (Beneš) を, 表 1 の構成で比較する. COGS 意味解析 [13] (24,155 件) は構成的汎化を測る評価用分割での完全一致

$$\text{削減率} = \frac{\Delta P}{\text{合計}} = \frac{(L_e + 2L_d)(2d^2 - d)}{\underbrace{Vd}_{\text{埋め込み}} + \underbrace{4(d^2 + d)(L_e + 2L_d)}_{\text{アテンション}} + \underbrace{(2df + f + d)(L_e + L_d)}_{\text{FFN}} + \underbrace{2d(2L_e + 3L_d + 2)}_{\text{LayerNorm}}} \quad (4)$$

表 2 主結果と削減率。「削減」は標準 (8.84M / 36.67M / 2.61M) に対して取り除いた割合. $\pm$ は COGS の上位 8 行が 5 回の学習の標準偏差, 他は評価事例を再抽出するブートストラップ 95% 信頼区間の半幅 (異なる量). 太字は局所置換・大域置換の中での各評価列の最高値. * は標準に対し, † は単純共有に対し $p < 0.05$.

モデル	COGS		IWSLT14		Multi30k	
	削減	汎化完全一致 $\uparrow$	削減	BLEU $\uparrow$	削減	BLEU $\uparrow$
標準	0.0%	76.41 $\pm$ 4.02	0.0%	33.45 $\pm$ 0.51	0.0%	40.78 $\pm$ 1.74
同規模標準	35.7%	79.46 $\pm$ 1.25	25.7%	32.94 $\pm$ 0.50*	13.6%	40.00 $\pm$ 1.69*
単純共有	35.5%	80.76 $\pm$ 1.06*	25.7%	31.58 $\pm$ 0.49*	15.0%	38.64 $\pm$ 1.64*
局所置換: 4 トークン	35.2%	79.07 $\pm$ 1.53	25.5%	31.70 $\pm$ 0.50*	14.5%	38.76 $\pm$ 1.64*
トークン別	35.2%	79.08 $\pm$ 1.47	25.5%	32.19 $\pm$ 0.49*†	14.5%	39.24 $\pm$ 1.66*
チャンネル群	35.5%	80.59$\pm$2.16	25.7%	31.71 $\pm$ 0.49*	15.0%	38.43 $\pm$ 1.66*
ベキ付き	35.5%	78.84 $\pm$ 2.96	25.7%	31.68 $\pm$ 0.49*	15.0%	38.92 $\pm$ 1.62*
全箇所	34.6%	80.01 $\pm$ 0.91	25.0%	32.19 $\pm$ 0.48*†	13.4%	39.35$\pm$1.71 *†
大域置換: Beneš	35.1%	76.04 $\pm$ 0.55	25.4%	32.21$\pm$0.50	14.3%	38.87 $\pm$ 1.60

率, Multi30k 英 $\rightarrow$ 独 [14] (29,000 件) と IWSLT14 独 $\rightarrow$ 英 [15] (160,239 件) は両言語共有の 10,000 ユニット BPE 語彙 [16, 17] で BLEU/13a [18] を測る. デコードはビーム幅 5, 差は対応ありブートストラップ [19] で検定する (多重比較は補正しない).

5 結果

表 2 に主な結果を示す. 単純共有は標準から Multi30k で 2.13, IWSLT14 で 1.86 BLEU 失う. 局所置換では, IWSLT14 のトークン別と全箇所の 2 変種が単純共有から 0.61 / 0.60 BLEU を, Multi30k では全箇所が 0.70 BLEU を有意に回復する (問い 1: 翻訳では改善). しかしいずれも同規模標準を 0.65–0.75 下回る (問い 2: 翻訳では届かない). COGS では単純共有が最も高く, どの変種も上回らない.

大域置換の Beneš は, IWSLT14 で 32.21 と局所置換の最良 (32.19) と同水準, Multi30k で 38.87 と局所置換の最良 (39.35) に届かず, COGS では 1 回の学習ではあるが 76.04 で単純共有を 4.72 ポイント下回り 9 モデル中最低である (問い 4: 上回らない). なお Beneš の Multi30k は 3 回の学習のうち開発 BLEU が最良の 1 本で, 有利な選び方でも上回らない. 問い 3 の対照実験では, 置換の合成について閉じていない (群をなさない) 8 置換集合 3 種の開発 BLEU 平均が 39.24 / 39.43 / 39.18 で, 類推 8 置換の 39.36 との差は +0.08, 正なのは 3 回の学習のうち 1 回である. 全 24 置換 (S_4) も 39.33 で同程度である (問い 3: D_8 特有の優位は見えない).

6 考察とまとめ

局所置換は単純共有の損失の約 3 分の 1 を有意に回復し, 学習済みモデルは $Q/K/V$ で互いに異なるほぼ離散的な置換を選んでいて (最大の混合重みの平均が 0.89–0.91, 役割間の混合重み分布の正規化 Jensen–Shannon ダイバージェンスが 0.85–0.88). Multi30k 開発集合でルータの出力を一樣分布に固定すると 1.3–2.2, ゲートを閉じると 2.2–11.6 BLEU 落ちる. 第 2.3 節の機構が実際に使われている証拠である.

一方, 期待した大域置換の Beneš は効かなかった. 理由は 3 つ考えられる. 第一に, Π_K, Π_V は静的である. 静的な置換は, 役割が 1 つだけならば W_S に吸収されてしまう (第 2.4 節). 3 つの役割が W_S を共有しているので Π_K, Π_V 自体は残るが, 増えるのは「どの 4 チャンネルを組にするか」の自由度だけで, 役割を入力に応じて作り分ける力は増えない. 第二に, この変種は倍率 λ_r を持たない. ただし倍率の有無だけを変えて学習したときの差は Multi30k の開発集合で +0.08 BLEU と小さく, この説明は弱い. 第三に, 勾配が近似であり, $d = 512$ では 4,352 個のスイッチが同時に動くため学習が不安定になった可能性がある.

言えるのは「入力と役割に条件付けられた局所的な置換の混合が対角行列を上回りうる」ところまでである. 類推は候補を絞る設計原理としては機能したが, 精度向上の要因とは示せていない. 今後は大域置換も入力に応じて選べるようにしたい.

参考文献

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, Vol. 30, pp. 5998–6008. Curran Associates, Inc., 2017.
- [2] Ali Kayyam, Anusha Madan Gopal, and M. Anthony Lewis. Do transformers need three projections? Systematic study of QKV variants. In *Proceedings of the 43rd International Conference on Machine Learning*, Vol. 306 of *Proceedings of Machine Learning Research*. PMLR, July 2026.
- [3] Yves Lepage and Miguel Couceiro. Numerical analogy revisited and extended, refined, shrunk or enlarged. In Anaëlle Wilczynski, François Schwarzentruher, and Jean-Guy Mailly, editors, *Proceedings of the 19th Journées d’Intelligence Artificielle Fondamentale (JIAF 2025)*, Dijon, France, July 2025. (in French).
- [4] Václav E. Beneš. Optimal rearrangeable multistage connecting networks. *Bell System Technical Journal*, Vol. 43, No. 4, pp. 1641–1656, 1964.
- [5] Joshua Ainslie, James Lee-Thorp, Michiel de Jong, Yury Zemlyanskiy, Federico Lebrón, and Sumit Sanghai. GQA: Training generalized multi-query transformer models from multi-head checkpoints. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 4895–4901, Singapore, December 2023. Association for Computational Linguistics.
- [6] Yi Tay, Dara Bahri, Liu Yang, Donald Metzler, and Da-Cheng Juan. Sparse Sinkhorn attention. In *Proceedings of the 37th International Conference on Machine Learning*, Vol. 119 of *Proceedings of Machine Learning Research*, pp. 9438–9447. PMLR, July 2020.
- [7] Peng Chen. PermuteFormer: Efficient relative position encoding for long sequences. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pp. 10606–10618, Online and Punta Cana, Dominican Republic, November 2021. Association for Computational Linguistics.
- [8] Md Kowsher, Nusrat Jahan Prottasha, Chun-Nam Yu, Ozlem Ozmen Garibay, and Niloofar Yousefi. Does self-attention need separate weights in transformers? In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 3: Industry Track)*, pp. 535–543, Albuquerque, New Mexico, April 2025. Association for Computational Linguistics.
- [9] Jean-Joseph Rallier des Ourmes. Proportion. In Denis Diderot and Jean le Rond d’Alembert, editors, *Encyclopédie, ou Dictionnaire raisonné des sciences, des arts et des métiers*, Vol. 13, pp. 466–470. Samuel Faulche & Compagnie, Neufchâtel, 1765.
- [10] Róbert Csordás, Kazuki Irie, and Jürgen Schmidhuber. The devil is in the detail: Simple tricks improve systematic generalization of transformers. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pp. 619–634, Online and Punta Cana, Dominican Republic, November 2021. Association for Computational Linguistics.
- [11] Felix Wu, Angela Fan, Alexei Baevski, Yann N. Dauphin, and Michael Auli. Pay less attention with lightweight and dynamic convolutions. In *7th International Conference on Learning Representations (ICLR 2019)*, New Orleans, Louisiana, 2019.
- [12] Zhiyong Wu, Lingpeng Kong, Wei Bi, Xiang Li, and Ben Kao. Good for misconceived reasons: An empirical revisiting on the need for visual context in multimodal machine translation. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pp. 6153–6166, Online, August 2021. Association for Computational Linguistics.
- [13] Najoung Kim and Tal Linzen. COGS: A compositional generalization challenge based on semantic interpretation. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 9087–9105, Online, November 2020. Association for Computational Linguistics.
- [14] Desmond Elliott, Stella Frank, Khalil Sima’an, and Lucia Specia. Multi30K: Multilingual English-German image descriptions. In *Proceedings of the 5th Workshop on Vision and Language*, pp. 70–74, Berlin, Germany, August 2016. Association for Computational Linguistics.
- [15] Mauro Cettolo, Jan Niehues, Sebastian Stüker, Luisa Bentivogli, and Marcello Federico. Report on the 11th IWSLT evaluation campaign. In *Proceedings of the 11th International Workshop on Spoken Language Translation: Evaluation Campaign*, pp. 2–17, Lake Tahoe, California, December 2014.
- [16] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 1715–1725, Berlin, Germany, August 2016. Association for Computational Linguistics.
- [17] Taku Kudo and John Richardson. SentencePiece: A simple and language independent subword tokenizer and detokenizer for Neural Text Processing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pp. 66–71, Brussels, Belgium, November 2018. Association for Computational Linguistics.
- [18] Matt Post. A call for clarity in reporting BLEU scores. In *Proceedings of the Third Conference on Machine Translation: Research Papers*, pp. 186–191, Brussels, Belgium, October 2018. Association for Computational Linguistics.
- [19] Philipp Koehn. Statistical significance tests for machine translation evaluation. In *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing*, pp. 388–395, Barcelona, Spain, July 2004. Association for Computational Linguistics.